




Aprendizaje de Máquina - A1

DETECCIÓN AUTOMÁTICA DE GRIETAS

en Estructuras de Concreto

Integrantes

María Fernanda Rojas, Angie Boada



Aprendizaje de Máquina - A1

»» Seguridad Estructural

»» Prevención de Colapsos

»» Mantenimiento Preventivo


INTRODUCCIÓN DEL PROBLEMA

»» Puentes y Edificios

Las grietas en puentes, edificios y otras estructuras requieren monitoreo constante para garantizar su integridad y seguridad pública.

»» Inspección Automatizada

La detección temprana mediante técnicas de visión por computadora permite intervenciones oportunas y reduce costos de reparación.





OBJETIVO DEL PROYECTO

Desarrollar un modelo de aprendizaje de máquina capaz de identificar y clasificar si una imagen presenta grietas o no.



Modelo de Machine Learning

Crear un modelo de aprendizaje automático capaz de detectar automáticamente grietas en imágenes de estructuras de concreto para aplicaciones de ingeniería civil.



Clasificación Binaria

Desarrollar sistema que clasifique imágenes de concreto en dos categorías: con grieta (Clase 1) vs sin grieta (Clase 0).



Enfoque Híbrido

Combinar modelos supervisados (KNN, Árbol de Decisión, Random Forest) con técnicas no supervisadas (PCA, KMeans, DBSCAN).



Automatización

Mejorar eficiencia y seguridad en inspecciones estructurales mediante detección automática de defectos.



Dataset de Imágenes

El dataset contiene imágenes de superficies de concreto etiquetadas en dos categorías para clasificación binaria. Cada imagen permite entrenar modelos de aprendizaje automático.

- ✓ Clase 0: Imágenes sin grieta
- ✓ Clase 1: Imágenes con grieta
- ✓ Balance de clases para entrenamiento
- ✓ Variabilidad en condiciones de captura





Escala de Grises



Resize 28×28



Normalización



Aplanado 784



Train/Test Split

PREPROCESAMIENTO DE IMÁGENES PARA MACHINE LEARNING


Cada imagen del dataset pasa por un pipeline de transformación antes de alimentar los modelos de clasificación. Este proceso estandariza los datos y reduce la complejidad computacional manteniendo la información relevante para detectar grietas.

El resultado final son vectores numéricos listos para entrenar modelos supervisados de clasificación binaria.



MODELOS SUPERVISADOS

Decision Tree




Clasifica la imagen mediante reglas basadas en los valores de los píxeles.

Random Forest




Combina varios árboles de decisión para mejorar precisión y robustez.

SVM



Separa las clases buscando una frontera entre imágenes con y sin grieta.

Deep Learning



Aprende patrones complejos en los píxeles para detectar grietas.



Con grieta




Sin grieta



1. ACCURACY POR MODELO



2. PRECISIÓN, RECALL Y F1



3. MATRIZ DE CONFUSIÓN

		Predicción	
		Grieta (Positivo)	Sin grieta (Negativo)
Realidad	Grieta (Positivo)	TP (Verdadero Positivo) 120	FP (Falso Positivo) 15
	Sin grieta (Negativo)	FN (Falso Negativo) 8	TN (Verdadero Negativo) 157

Más Frecuente

Menos Frecuente

EVALUACIÓN DE LOS MODELOS

Métricas clave de clasificación



Accuracy – Aciertos generales



Precisión – Confiabilidad al predecir grieta



Recall – Grietas reales detectadas



F1-Score – Balance entre precisión y recall



RECALL ES LA MÉTRICA CLAVE


Porque reducir los falsos negativos disminuye el riesgo de **no detectar grietas reales**.



MODELOS NO SUPERVISADOS

PCA - REDUCCIÓN DE DIMENSIONALIDAD

- Se usó StandardScaler para escalar los datos.
- Las imágenes originalmente tenían 784 columnas.
- Se aplicó PCA con $n_components = 2$.
- El objetivo fue reducir la dimensionalidad del dataset a dos componentes principales para poder visualizarlo en un plano 2D.
- Se graficó el dataset original proyectado con PCA usando las etiquetas reales solo como referencia visual.






MODELOS NO SUPERVISADOS

KMEANS SOBRE PCA

- KMeans se aplicó sobre el dataset reducido con PCA.
- Se usó `n_clusters = 2` porque el dataset tiene dos clases reales: sin grieta y con grieta.
- KMeans no usa las etiquetas reales para entrenar.
- KMeans agrupa los datos según la distancia de los puntos a los centroides.
- Se graficaron los clusters generados por KMeans y sus centroides.





Detección de
Grietas

MODELOS NO SUPERVISADOS

DBSCAN

(Density-Based Spatial Clustering of Applications with Noise) es un algoritmo de agrupamiento basado en densidad. No utiliza etiquetas reales para el entrenamiento, revelando la estructura natural del dataset de imágenes de concreto proyectadas en el espacio PCA bidimensional.



Gráfica K-Distancia

La gráfica k-distancia ayuda a seleccionar el valor óptimo de ϵ . Se busca el "codo" donde la distancia aumenta bruscamente para definir el umbral adecuado.



Sin Clusters Predefinidos

A diferencia de KMeans, DBSCAN no requiere especificar el número de clusters previamente. Descubre grupos basándose en la densidad de los datos.



Parámetros Clave

ϵ : distancia máxima entre puntos para considerarlos vecinos. min_samples : mínimo de puntos para formar una región densa.



Detección de Ruido

Los puntos que no pertenecen a ningún cluster se etiquetan como ruido (-1). Útil para identificar imágenes atípicas o anomalías.



Random Forest

Mejor modelo supervisado



PCA

Visualización efectiva
(784 → 2)



KMeans

Identificación de clusters



DBSCAN

Detección de ruido
y densidad



Futuro

CNN y Deep Learning

COMPARACIÓN FINAL Y CONCLUSIONES DEL PROYECTO



Hallazgos principales

- Random Forest logró el mejor desempeño en la clasificación de grietas.
- PCA redujo la dimensionalidad y facilitó la visualización del dataset.
- KMeans y DBSCAN permitieron analizar agrupamientos naturales sin usar etiquetas.



Conclusión

El proyecto combinó aprendizaje supervisado para clasificar grietas y aprendizaje no supervisado para analizar la estructura interna de los datos.



Mejoras futuras

Usar imágenes de mayor resolución, ampliar el dataset y explorar modelos CNN para mejorar el desempeño.



Aprendizaje de
Máquina - A1

¡GRACIAS!



Angie Boada



María Fernanda Rojas

